



X

VERİ BİLİMİ İÇİN İSTATİSTİK

PROJE ÖDEVİ

Yapay Zeka ve Makine Öğrenmesi Bölümü - 2. Sınıf

2025-2026 Bahar Dönemi

İsim:Rümeysa

Soyisim : YEŞİLOVA

Öğrenci no : 250121044

Proje 5: Merkezi Limit Teoremi Simülasyonu ve Analizi

1. Giriş

1.1. Veri Bilimi ve İstatistiksel Çıkarım

Günümüz veri bilimi dünyasında, yapay zeka modellerinin başarısı büyük ölçüde verinin altında yatan olasılık dağılımlarının doğru analiz edilmesine dayanmaktadır. Karmaşık veri setleri üzerinde yapılan öngörüler, çoğu zaman verinin belirli bir matematiksel yapıya uyduğu varsayımıyla gerçekleştirilir. Ancak gerçek dünya senaryolarında; kullanıcı davranışları, sensör verileri veya finansal işlemler nadiren "ideal" bir normal dağılım sergiler. Verinin bu heterojen yapısı ile istatistiksel analiz yöntemlerinin talep ettiği homojenlik arasındaki en güçlü köprü, "Merkezi Limit Teoremi"dir (MLT).

1.2. Merkezi Limit Teoremi'nin Teorik ve Tarihsel Önemi

Merkezi Limit Teoremi, olasılık teorisinin taçlandırılmış başarısı olarak kabul edilir. Tarihsel süreçte De Moivre, Laplace ve son olarak Lyapunov gibi matematikçilerin katkılarıyla şekillenen bu teorem; popülasyon dağılımı ne kadar asimetrik, çarpık veya düzensiz olursa olsun, bu popülasyondan çekilen bağımsız ve aynı dağılıma sahip (i.i.d.) rassal değişkenlerin ortalamasının, örneklem boyutu (n) arttıkça Gauss (Normal) dağılımına yakınsayacağını ifade eder.

Bu yakınsama, istatistikteki "Büyük Sayılar Yasası" (Law of Large Numbers) ile karıştırılmamalıdır. Büyük Sayılar Yasası, örneklem ortalamasının popülasyon ortalamasına yaklaştığını söylerken; Merkezi Limit Teoremi, bu ortalamaların oluşturduğu dağılımın **şekli** hakkında bilgi verir. Bu şekil, modern istatistiğin bel kemiği olan "Standart Normal Dağılım"dır.

1.3. Makine Öğrenmesi ve Yapay Zeka Açısından Motivasyon

Yapay zeka ve makine öğrenmesi algoritmalarının çoğu, MLT varsayımı üzerine inşa edilmiştir. Örneğin:

- **Parametrik Testler:** t-testi ve ANOVA gibi testler, hata terimlerinin normal dağıldığını varsayar.
- **Model Optimizasyonu:** Gradyan inişi (Gradient Descent) gibi optimizasyon süreçlerinde kullanılan hata metrikleri çoğu zaman normal dağılım beklentisiyle kurgulanır.
- **Tahmin Güven Aralıkları:** Bir modelin çıktısına dair güven aralıkları hesaplanırken, örneklem dağılımının normal olduğu varsayımıyla Z-skorları veya t-skorları kullanılır.

Bu çalışmada, Kocaeli Üniversitesi Yapay Zeka ve Makine Öğrenmesi Bölümü bünyesinde yürütülen akademik standartlar çerçevesinde; MLT'nin sadece teorik bir ifade olmaktan çıkarılıp, deneysel (ampirik) bir kanıtla desteklenmesi hedeflenmiştir.

1.4. Çalışmanın Amacı ve Kapsamı

Bu projenin temel motivasyonu, Merkezi Limit Teoremi'nin işleyiş mekanizmasını farklı olasılık yoğunluk fonksiyonları üzerinden test etmektir. Çalışma kapsamında şu sorulara yanıt aranacaktır:

1. Başlangıç dağılımı aşırı çarpık (Üstel) veya kesikli (Poisson/Binom) olsa dahi normale yakınsama gerçekleşir mi?

2. Literatürde "sihirli sayı" olarak kabul edilen $n=30$ eşiği, tüm dağılım türleri için yeterli midir?
3. Örneklem boyutu arttıkça Shapiro-Wilk p-değeri ve Q-Q grafiği sapmaları nasıl bir trend sergiler?

Raporun ilerleyen bölümlerinde, Uniform, Üstel, Poisson ve Binom dağılımları üzerinden gerçekleştirilen 10.000 tekrarlı simülasyonların sonuçları; matematiksel formüller, görselleştirme araçları ve analitik testler eşliğinde tartışılacaktır.

2. METODOLOJİ VE SİMÜLASYON ALTYAPISI

2.1. Simülasyon Tasarımı ve Rastgele Sayı Üretimi (RNG)

Bu çalışmada, Merkezi Limit Teoremi'nin (MLT) asimptotik davranışını inceleyebilmek için sözde rastgele sayı üreteçleri (Pseudo-Random Number Generators - PRNG) kullanılarak bir Monte Carlo simülasyonu kurgulanmıştır. Analizin deterministik ve yeniden üretilebilir (reproducible) olmasını sağlamak amacıyla, Python'ın `numpy.random` modülü üzerinden global bir "seed" (çekirdek) değeri sabitlenmiştir.

Simülasyon döngüsünde, örneklem boyutunun (n) popülasyon dağılımı üzerindeki etkisini hassas bir şekilde gözlemleyebilmek için $n \in \{2, 5, 10, 30, 50, 100\}$ seti belirlenmiştir. Her bir n değeri ve her bir dağılım türü için 10.000 iterasyon yapılarak toplamda bağımsız rastgele örneklemeler çekilmiş ve bu örneklemelerin aritmetik ortalamaları ($\bar{X}$) hesaplanarak yeni bir "örneklem ortalamaları dağılımı" elde edilmiştir.

2.2. Kullanılan Olasılık Dağılımları ve Teorik Karakteristikleri

Simülasyonun sağlamlığını test etmek için, bilinçli olarak birbirinden tamamen farklı yapısal özelliklere sahip (simetrik, sağa çarpık ve kesikli) dört temel dağılım seçilmiştir.

2.2.1. Sürekli Düzgün (Uniform) Dağılım

Verilerin belirli bir $[a, b]$ aralığında tamamen eşit olasılıkla gerçekleştiği, simetrik ve kuyrukları olmayan sürekli bir dağılımdır. Simülasyonda standart düzgün dağılım olan

$X \sim U(0, 1)$ kullanılmıştır.

- **Olasılık Yoğunluk Fonksiyonu (PDF):**

$$f(x) = \frac{1}{b-a} \text{ (sadece } a \leq x \leq b \text{ için)}$$

- **Beklenen Değer:** $E[X] =$

$$E[X] = \frac{a+b}{2} = 0.5$$

- **Varyans:**

$$\frac{(b-a)^2}{12} = \frac{1}{12} \approx 0.0833$$

2.2.2. Üstel (Exponential) Dağılım

Özellikle kuyruk teorisinde ve olaylar arası bekleme sürelerinin modellenmesinde kullanılan, doğası gereği oldukça asimetrik ve sağa çarpık (positive skewness) bir sürekli dağılımdır. Bu ekstrem asimetri, küçük n değerlerinde MLT'nin ne kadar zorlandığını göstermek için ideal bir test ortamı sunar. Oran parametresi $\lambda = 1$ olarak ayarlanmıştır.

- **Olasılık Yoğunluk Fonksiyonu (PDF):**

$$f(x) = \lambda e^{-\lambda x} \text{ (sadece } x \geq 0 \text{ için)}$$

- **Beklenen Değer:**

$$E[X] = \frac{1}{\lambda} = 1.0$$

- Varyans:

$$= \frac{1}{\lambda^2} = 1.0$$

2.2.3. Poisson Dağılımı

Belirli bir zaman aralığında veya uzamsal alanda nadir gerçekleşen olayların frekansını modelleyen kesikli (discrete) bir dağılımdır. Kesikli yapısının, n büyüdükçe nasıl sürekli bir normal dağılıma evrildiğini gözlemlemek için seçilmiştir. Ortalama gerçekleşme sıklığı $\lambda = 5$ olarak belirlenmiştir.

- Olasılık Kütle Fonksiyonu (PMF):

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

- Beklenen Değer:

$$E[X] = \lambda = 5.0$$

- Varyans:

$$Var(X) = \lambda = 5.0$$

2.2.4. Binom (Binomial) Dağılımı

n sayıda bağımsız Bernoulli denemesindeki başarılı sonuçların sayısını ifade eden kesikli bir dağılımdır. Proje yönergesi doğrultusunda, deneme sayısı $n_{\text{binom}}=20$ ve başarı olasılığı $p=0.3$ olarak parametreleştirilmiştir. Dağılımın $p \neq 0.5$ olması nedeniyle hafif bir asimetri barındırmaktadır.

- Olasılık Kütle Fonksiyonu (PMF):

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

- Beklenen Değer: $E[X] =$

$$E[X] = n \cdot p = 20 \times 0.3 = 6.0$$

- **Varyans:** $\text{Var}(X) =$

$$\text{Var}(X) = n \cdot p \cdot (1 - p) = 20 \times 0.3 \times 0.7 = 4.2$$

2.3. İstatistiksel Testler ve Görselleştirme Altyapısı

Elde edilen 10.000'er adetlik örneklem ortalamalarının teorik normal dağılıma yakınsaklığı iki aşamalı olarak analiz edilmiştir.

1. Analitik Doğrulama (Shapiro-Wilk Testi):

Literatürde normallik testi için yaygın olarak kullanılan Kolmogorov-Smirnov testine kıyasla, Shapiro-Wilk testi özellikle istatistiksel gücü (statistical power) yüksek olduğu için tercih edilmiştir. Testin test istatistiği (W), verilerin varyansının iki farklı tahmininin oranına dayanır. Çalışmada, hesaplama yükünü optimize etmek adına (Shapiro-Wilk'in 5000 üzeri N değerlerinde p-değerini hassas verememesi veya uyarı üretmesi nedeniyle) 10.000 veriden rastgele 5.000 örneklem seçilerek test istatistiği hesaplanmıştır. Anlamlılık düzeyi $\alpha = 0.05$ olarak belirlenmiştir.

2. Görsel Doğrulama (Histogram ve Q-Q Plot):

Histogram grafikleri üzerine; mu değeri orijinal dağılımın

beklenen değeri, standart sapması ise $\sigma_{\text{teorik}} = \frac{\sigma}{\sqrt{n}}$ olan teorik


$N(\mu, \sigma^2/n)$ normal eğrileri çizdirilerek ampirik veri ile teorik beklenti örtüştürülmüştür. İlaveten, verilerin kantilleri ile teorik normal dağılımın kantillerini karşılaştıran Q-Q (Quantile-Quantile) grafikleri kullanılarak kuyruk davranışlarındaki sapmalar detaylıca incelenmiştir.

3. Analiz ve Sonuçlar

Bu bölümde, dört farklı olasılık dağılımından çekilen örneklemelerin Merkezi Limit Teoremi'ne (MLT) uygunluğu hem görsel araçlar (Histogram ve Q-Q Grafikleri) hem de analitik istatistiksel testler (Shapiro-Wilk) aracılığıyla detaylı olarak incelenmiştir.

3.1. Görsel Analiz (Histogramlar ve Q-Q Grafikleri)

Merkezi Limit Teoremi'nin (MLT) etkisini ampirik olarak gözlemlemenin en etkili yolu, örneklem ortalamalarının dağılımını farklı n boyutları için görselleştirmektir. Bu doğrultuda, her bir dağılım ve örneklem boyutu kombinasyonu için elde edilen 10.000 adet örneklem ortalamasının frekans dağılımları histogramlar aracılığıyla çizdirilmiş ve üzerine teorik normal dağılım eğrisi (kırmızı çizgi) eklenmiştir.




Şekil 1: Dört farklı popülasyon dağılımı (Uniform, Üstel, Poisson, Binom) için farklı örneklem boyutlarında

$(n \in \{2, 5, 10, 30, 50, 100\})$ hesaplanan örneklem ortalamalarının histogramları ve beklenen teorik normal eğriler.

Şekil 1 incelendiğinde, sol sütunlardan sağ sütunlara doğru (örneklem boyutu büyüdükçe) dağılımların şeklindeki dramatik değişim net bir şekilde görülmektedir. Üstel ve Poisson gibi küçük n değerlerinde belirgin şekilde sağa çarpık (pozitif skewness) olan dağılımlar, $n \geq 30$ seviyesine ulaşıldığında asimetrik yapılarını tamamen kaybederek kusursuz bir simetrik çan eğrisine dönüşmüştür.

Bu görsel bulguların teorik normal dağılım ile yapısal uyumunu daha hassas bir şekilde test etmek amacıyla, aynı veri setleri üzerinden Q-Q (Quantile-Quantile) grafikleri oluşturulmuştur.



Şekil 2: Farklı örneklem boyutlarında elde edilen örneklem ortalamalarının (mavi noktalar) teorik normal dağılım kantilleriyle (kırmızı referans çizgisi) karşılaştırıldığı Q-Q grafikleri.

Şekil 2'deki Q-Q grafikleri, histogramlardaki bulguları destekler niteliktedir. Küçük örneklem boyutlarında ($n=2, 5, 10$), özellikle Üstel dağılımda gözlemlenen ve ağır kuyruk davranışına işaret eden "S" şeklindeki sapmalar dikkat çekicidir. Bu durum, söz konusu n değerlerinde verinin normal dağılımdan anlamlı ölçüde saptığını gösterir. Ancak n boyutu 30 ve üzerine çıktığında, başlangıçtaki dağılımın şekli ne kadar düzensiz olursa olsun, tüm mavi veri noktalarının kırmızı referans çizgisi üzerine mükemmel bir şekilde oturduğu (doğrusal bir ilişki sergilediği) gözlemlenmiştir. Bu durum, verilerin normal dağılımın teorik kantilleri ile eşleştiğinin en güçlü görsel kanıtıdır.

3.2. Analitik Analiz (Shapiro-Wilk Normallik Testi)

Görsel bulguların istatistiksel olarak anlamlılığını ölçmek amacıyla 5000 rastgele örneklem üzerinden Shapiro-Wilk testi uygulanmıştır ($\alpha = 0.05$).

- Orijinal olarak simetrik bir yapıya daha yakın olan Uniform dağılımında, $n=30$ seviyesinde hesaplanan p -değeri 0.05 'in üzerine çıkarak H_0 (Veriler normal dağılımdan gelmektedir) hipotezinin reddedilemeyeceğini göstermiştir.

- Ancak yüksek çarpıklığa sahip Üstel ve Poisson dağılımlarında, küçük n değerlerinde p -değeri 0.0000 olarak bulunmuş ve H_0 hipotezi kesin bir dille reddedilmiştir. Bu dağılımların istatistiksel olarak normal kabul edilebilmesi için n değerinin daha da artması (bazı durumlarda >50) gerektiği test sonuçlarına yansımıştır. Eklenen Binom dağılımında ($n=20, p=0.3$) ise kesikli ve hafif çarpık yapı, n büyüdükçe sürekli bir normal dağılıma pürüzsüz bir şekilde evrilmiştir.

4. Tartışma

Gerçekleştirilen bu kapsamlı simülasyon, istatistiksel modelleme ve makine öğrenmesi algoritmalarının temelini oluşturan varsayımların sınırlarını tartışmak için önemli bulgular sunmaktadır. Literatürde genellikle "sihirli sayı" olarak kabul edilen $n \geq 30$ kuralının, her dağılım için mutlak bir doğru olmadığı ampirik olarak kanıtlanmıştır.

Özellikle aykırı değerlerin (outliers) ve ağır kuyrukların (heavy-tails) yoğun olduğu gerçek dünya veri setlerinde (örneğin kredi kartı sahtekarlığı veya ağ anomali tespiti verileri), Merkezi Limit Teoremi'ne güvenerek normallik varsayımı yapmadan önce dağılımın çarpıklık derecesi mutlaka dikkate alınmalıdır. Aksi takdirde, model performans değerlendirmelerinde (örneğin yanlış kurulan güven aralıklarında) Tip I ve Tip II hataların artması kaçınılmazdır.

5. Sonuç ve Öneriler

Bu projede, Python (NumPy ve SciPy) tabanlı bir simülasyon ortamı kurgulanarak Merkezi Limit Teoremi doğrulanmıştır. Düzgün, Üstel, Poisson ve Binom dağılımları üzerinden toplamda 240.000 iterasyon gerçekleştirilmiş olup, n örneklem boyutu arttıkça dağılımların teorik normal dağılıma $(X \sim N(\mu, \sigma^2/n))$ yakınsadığı hem grafiksel (Q-Q, Histogram) hem de hipotez testleri ile ispatlanmıştır.

6. KAYNAKÇA

1. **Casella, G., & Berger, R. L.** (2021). *Statistical Inference* (2nd ed.). Cengage Learning. (Merkezi Limit Teoremi ve olasılık dağılımları teorik altyapısı için).
2. **Downey, A. B.** (2014). *Think Stats: Exploratory Data Analysis in Python*. O'Reilly Media.
3. **NumPy Geliştirici Ekibi.** (2026). *NumPy Documentation*. Erişim adresi: <https://numpy.org/doc/>
4. **SciPy Topluluğu.** (2026). *SciPy Statistical Functions (scipy.stats)*. Erişim adresi: <https://docs.scipy.org/doc/scipy/reference/stats.html>
5. **Matplotlib Geliştirme Ekibi.** (2026). *Matplotlib: Visualization with Python*. Erişim adresi: <https://matplotlib.org/stable/gallery/>